FH AACHEN
UNIVERSITY OF APPLIED SCIENCES

Applied Data Analytics

WiSe 2025/2026

Bericht zum Praktikum

Kundensegmentierung mittels Clustering im Einzelhandel

Autoren: Kilic, Topal, Cobanoglu

Abgabe: 19.01.2026

Inhalt

Abschnitt 1: Projektteam 3
Abschnitt 2: Datensätze 3
Abschnitt 3: Vorverarbeitung und Explorative Datenanalyse 4
Abschnitt 4: Einordnung des Anwendungproblems 6
Abschnitt 5: Interpretation und Fazit 7
Abschnitt 6: Quellen und Links 8

Abschnitt 1: Projektteam

Name	Vorname	Matrikelnummer	E-Mail
Kilic	Egehan	3655034	egehan.kilic@alumni.fh-aachen.de
Topal	Ahmet	3575440	ahmet.topal@alumni.fh-aachen.de
Cobanoglu	Enis	3616084	enis.cobanoglu@alumni.fh-aachen.de

Aufgabenverteilung

Kilic, Egehan	Interpretation der Kundencluster, Datensatzreinigung & Preprocessing, Marketingstrategien abgeleitet & Berichtausarbeitung
Topal, Ahmet	Datenvorbereitung, Explorative Datenanalyse (EDA), Visualisierung & Diagramme, Strukturierung der Präsentation & Bericht
Cobanoglu, Enis	Clustering-Auswahl, Modellbewertung, Implementierung des K-Means Clustering, Mitwirkung Präsentation & Bericht

Abschnitt 2: Datensätze

Anbei sind Informationen über den verwendeten Datensatz:

Herkunft des Datensatzes:

- Datensatz Online Retail [D1]
- UCI Machine Learning Repository – London South Bank University, School of Engineering [D1]
- https://archive.ics.uci.edu/dataset/352/online+retail [D1]

Informationen zum Datensatz:

Der Datensatz enthält Transaktionsdaten eines britischen Online-Einzelhändlers [D1]. Er umfasst alle Rechnungspositionen im Zeitraum vom 01.12.2010 bis zum 09.12.2001 und besteht aus ungefähr 540.000 Zeilen. Jeder dieser einzelnen Zeilen ist eine einzelne Produktbuchung auf einer Rechnung und enthält unter anderem eine Rechnungsnummer (InvoiceNo), ein Produktcode (StockCode), eine Produktbeschreibung (Description), die bestellte Menge (Quantity), den Einzelpreis (UnitPrice), das Rechnungsdatum (InvoiceDate), eine Kundennummer (CustomerID) und auch ebenfalls das Land (Country) [D1].

Die Daten bilden damit also ein reales Kaufverhalten von mehr als 4.000 Kunden ab. Sie erlauben die Analyse von Warenkörben, Kaufhäufigkeit und Umsatz. Darüber hinaus sind nicht alle Informationen direkt für die Segmentierung von Kunden nutzbar, denn: Es gibt zum Beispiel Stornierungen (InvoiceNo mit dem Präfix „C“) sowie Transaktionen ohne hinterlegte CustomerID (siehe Abbildung 1). Diese Einträge müssen im Kontext der Datenverarbeitung bereinigt oder ausgeschlossen werden.

Insgesamt stellt der Datensatz eine gute Grundlage dar, um mithilfe von Clustering unterschiedlichen Kundentypen anhand ihres Kaufverhaltens zu identifizieren. Da der Datensatz reale Transaktionsdaten über einen längeren Zeitraum enthält, können inaktive und aktive Kundengruppen betrachtet werden.

Abschnitt 3: Vorverarbeitung und Explorative Datenanalyse

Für die Datenaufbereitung wurde der Datensatz erst einmal aufbereitet, bereinigt und auf Kundenebene zusammengeführt, um eine aussagekräftige Grundlage für die anschließende Clusteranalyse zu schaffen. Weil es sich um reale Transaktionsdaten handelt, mussten wir mehrere Schritte durchführen, um fehlerhafte oder doppelte oder sogar irrelevante Informationen zu entfernen und die ganzen Variablen für das Modell nutzbar zu machen (Datenquelle siehe [D1]).

3.1 Datenumfang und Merkmalsstruktur

Der ursprüngliche Datensatz umfasst insgesamt 541.909 Transaktionen über den Zeitraum von Dezember 2010 bis Dezember 2011 [D1]. Nach Bereinigung und nach Aggregation bleiben ca. 400.000 Transaktionen und 4338 Kunden übrig. Insgesamt stehen acht Merkmale zur Verfügung, wobei für die anschließende Clusteranalyse die kaufrelevanten Variablen genutzt wurden (siehe Abbildung 1):

Merkmal	**Bedeutung**
InvoiceNo	Rechnungsnummer der Transaktion
StockCode	Productcode
Description	Produktbeschreibung
Quantitiy	Bestellmenge pro Produktposition
InvoiceDate	Zeitstempel der Bestellung
UnitPrice	Prei pro Einheit
CustomerID	Eindeutige Kunden-ID
Country	Herkunftsland des Kunden

Nicht alle Variablen sind gleichmäßig relevant für die Segmentierung. Aus diesem Grund wurden erst einmal nur Merkmal berücksichtigt, die direkt Rückschlüsse auf Einkaufsverhalten und Kundenwert zulassen.

3.2 Umgang mit fehlenden Werten

Im Datensatz traten einige fehlende Werte hauptsächlich im Feld CustomerID auf. Weil Transaktionen ohne Kundennummer keinem Kundenprofil zugeordnet werden können, wurden diese Datensätze entfernt. Dadurch reduzierte sich der Datensatz auf Transaktionen mit gültiger Kunden-ID.

Zusätzlich wurden fehlerhafte oder weniger sinnvolle (im Sinne von unplausibel) Werte ausgeschlossen: Quantity <= 0 wurde als fehlerhaft eingestuft, bei UnitPrice <= 0 war ein Ausschluss oder eine Bereinigung notwendig und Stornierungen (InvoiceNo beginnt mit „C“) wurden vollständig entfernt. Mit diesem Schritt wurde sichergestellt, dass nur real getätigte Käufe in die Analyse einfließen (vgl. Abbildung 1).

3.3 Prüfung auf Ausreißer

Da reale Kundentransaktionen häufig stark variieren, wurden die Merkmale auf Ausreißer untersucht. Besonders bei Monetary (Gesamtumsatz) traten sehr hohe Einzelwerte auf. Diese stammen typischerweise von wenigen Großkunden.

Aus „geschäftlicher“ Sicht sind diese Werte relevant. Deshalb wurden die Ausreißer nicht entfernt, sondern bewusst im Datensatz belassen (vgl. Abbildung 1, Datensatzquelle [D1]). Dadurch bleibt die natürliche Heterogenität des Kaufverhaltens erhalten, was wiederum für die Clusterbildung entscheiden ist, um z.B. Premium-Kunden von Gelegenheitskäufern abzugrenzen.

3.4 Bildung neuer Merkmale (Feature Engineering)

Für die spätere Kundensegmentierung wurde das RFM-Modell berechnet. Dazu erfolgte erst einmal eine, wie schon oft erwähnt, Aggregation auf Kundenebene. Grundlage hierfür waren die Rohdaten aus dem Online-Retail Datensatz [D1]. Aus den ursprünglichen Transaktionen wurden drei zentrale Kennzahlen abgeleitet:

Feature: Recency, **Bedeutung**: Tage seit letztem Kauf, **Formel**: Heute – letzter Kauf

Feature: Frequency, **Bedeutung**: Anzahl Käufe pro Kunde, **Formel**: Anzahl Rechnungen

Feature: Monetary, **Bedeutung**: Umsatz pro Kunde, **Formel**: Summe (Quantity x Unitprice)

Diese drei Merkmale bilden die Basis des späteren Clusterings und werden im weiteren Verlauf visuell betrachtet, wobei Unterschiede im Kundenverhalten deutlich erkennbar werden (vgl. Abbildung 1 und 2). Für K-Means mussten die Werte zuvor standardisiert werden, was über eigenen Code [C1] und über skicit-learn [P5 & P3] umgesetzt wurde.

3.5 Explorative Datenanalyse (Kennzahlen & Interpretation)

Zur ersten Einschätzung des Kundenverhalten wurden statistische Grundauswertungen durchgeführt:

Der Mittelwert für die Recency beträgt 153 Tage, für die 4,7 Käufe und für die Monetary 2543 Pfund. Die Standardabweichung für die Recency beträgt 100 Tage, für die Frequency 7,7 und für die Monetary 8939 Pfund. Hinsichtlich des Maximums haben wir für die Frequency mehr als 200 Läufe und für die Monetary 126.026 Pfund.

Aus dieser Explorativen Datenanalyse lassen ich also einige Kennzahlen ermitteln und aus diesen Kennzahlen wiederum kann man einige Erkenntnisse gewinnen:

Es liegt eine Heterogenität im Kaufverhalten aufgrund der hohen Streuung vor. Außerdem kaufen viele Kunden selten, was für Gelegenheits- & Inaktivkunden spricht, und wenige Kunden kaufen viel, weshalb der Pareto-Effekt sichtbar ist. Zudem ist der Umsatz stark rechtsverteilt, was wiederum auf einzelne sehr profitable Kunden indiziert (vgl. Abbildung 2).

3.6 Grafische Analyse & Mustererkennung

Die grafische Analyse zeigt bereits deutliche Muster im Kaufverhalten. Niedrige Recency geht häufig mit höheren Umsätzen einher, während viele inaktive Kunden nur geringe Umsätze erzielen. Im Vergleich von Frequency und Monetary wird der 80/20-Effekt sichtbar: wenige Vielkäufer sorgen für den Großteil des Umsatzes. Diese Zusammenhänge werden in den Scatterplots gut sichtbar (siehe Abbildung 1 und Abbildung 2). Die Plots deuten somit früh auf verschiedene Kundensegmente hin, was später durch das Clustering bestätigt wurde (vgl. Ergebnisse Abschnitt 5 & [L1]).

Abschnitt 4: Einordnung des Anwendungsproblems

Nachdem im vorigen Abschnitt die Datenaufbereitung, EDA und grundlegende Muster im Kundenverhalten dargestellt wurden, folgt nun die inhaltliche Einordnung der Analyse im Kontext des maschinellen Lernens.

4.1 Beschreibung des Anwendungsproblems

In diesem Projekt wird untersucht, wie Kunden anhand ihres Kaufverhaltens automatisiert segmentiert werden können. Der Fokus liegt darauf, Muster in Online-Transaktionsdaten zu erkennen und Kundengruppen abzuleiten, die sich in Aktivität, Kaufhäufigkeit und Umsatz bedeutend unterscheiden. Unternehmen stehen nämlich häufig vor der Herausforderung, große Datenmengen zwar zu besitzen, aber nicht effizient für Marketing- und Bindungsstrategien zu nutzen. Studien zeigen, dass RFM-basiertes Clustering ein geeignetes Verfahren zur Kundensegmentierung im E-Commerce ist (vgl. [L1]).

Die Kundensegmentierung mittels Maschine Learning kann hier helfen, Zielgruppen besser zu verstehen, personalisierte Angebote zu entwickeln und Ressourcen effizienter einzusetzen. Die spätere Visualisierung der Kundensegmente verdeutlicht diese Unterschiede deutlich (vgl. Abbildung 4).

4.2 Art des Lernproblems

Weil der Datensatz keine Zielvariable enthält und keine vorgegebene Kundenlabels existieren, handelt es sich um ein unüberwachtes Lernproblem. Das Ziel ist nicht die Vorhersage eines Outcomes, sondern vielmehr das Erkennen von Strukturen und Ähnlichkeiten in Kundendaten. Clustering ist deshalb eine geeignete Methode, da sie natürliche Gruppen in den Daten ohne Vorkennnisse erkennt, was auch in der Literatur bestätigt wird (vgl. [L2]). Die Qualitätsbewertung der Cluster erfolgt später über Kennzahlen wie den Silhouette-Score (vgl. Abbildung 3).

4.3 Forschungsfragen (Detailfragen zur Analyse)

Zur strukturierten Bearbeitung des Projekts haben wir drei Kernfragen definiert:

1. Welche Kundensegmente lassen sich anhand der RFM-Merkmale unterscheiden?
2. Welche Merkmale sind besonders aussagekräftig zur Differenzierung von Kunden?
3. Welche Marketingmaßnahmen können aus den Segmenten abgeleitet werden?

Diese Forschungsansätze orientieren sich an gängigen Clustering-Anwendungen im Marketing-Umfeld (vgl. [L1], [L2]).

4.4 Verwendetes Modell des Maschinellen Lernens

Für die Segmentierung wurde der Algorithmus K-Means Clustering eingesetzt, da er numerische Daten gut gruppieren kann und in der Praxis häufig zur Kundensegmentierung genutzt wird (vgl. [L1] & [L2]).

Vor Trainingsbeginn wurden die Daten bereinigt, neue Merkmale (LiveRevenue) erzeugt und anschließend standardisiert, um gleiche Gewichtung sicherzustellen (Standardisierung umgesetzt im eigenen Code [C1]).

Zur Bestimmung der optimalen Clusteranzahl kamen zwei Verfahren zum Einsatz: Silhouette-Score (Ziel: maximal) und Davied-Bouldin-Index (Ziel: minimal). Beide Metriken deuten auf k = 5 als optimale Clusteranzahl hin (siehe Abbildung 3). Anschließend erfolgten das endgültige Training und die Zuweisung jedes Kunden zu genau einem Cluster.

4.5 Verwendete Metriken zur Bewertung

Die Qualität des Modells wurde anhand folgender Kennzahlen bewertet:

Metrik: Silhouette-Score, Ergebnis: ~0,62, Interpretation: Gute Clustertrennung, klare Gruppierung

Metrik: Davies-Bouldin-Index, Ergebnis: ~0,71, Interpretation: Cluster kompakt, geringe Überlappung

Beide Werte sprechen für ein stabiles, sinnvolles Clustering. Kleinere Überschneidungen sind bei realen Kundendaten erwartbar (vgl. Abbildung 3; theoretischer Hintergrund in [L2]). Kleine Überschneidungen sind typisch für natürliche Verhaltensdaten.

4.6 Bewertung der Modellleistung

Das Modell bildet fünf unterscheidbare Kundengruppen, darunter befinden sich Gelegenheitskäufer, Inaktive Kunden, Stammkunden, Premiumkunden und Potenzialkunden. Die Cluster sind sowohl statistisch als auch visuell klar voneinander abgegrenzt (siehe Abbildung 4).

Damit eignet sich das Modell gut für strategische Marketingentscheidungen, etwas Rabattkampagnen, Bindungsstrategien oder Upselling-Maßnahmen. Die Ergebnisse sind aussagekräftig, nachvollziehbar und erzeugen dementsprechend auch ebenfalls einen realen geschäftlichen Mehrwert. Zudem stehen die Resultate im Einklang mit bisherigen Forschungsergebnissen (vgl. [L1]).

Abschnitt 5: Interpretation und Fazit

Im Rahmen der Analyse wurde anhand des Online-Retail-Datensatze erfolgreich eine Kundensegmentierung mittels K-Means-Clustering durchgeführt (vgl. [D1]). Die vorangegangene explorative Datenanalyse zeigt bereits deutliche Muster im Kaufverhalten, welche sich anschließend in den finalen Clustern widerspiegelten. Besonders die RFM-Merkmale (Recency, Frequency und Monetary) erwiesen sich, wie auch in der Literatur beschrieben, als robuste Grundlage zur Kundenklassifikation (vgl. [L1]).

Durch die Anwendung des K-Means-Algorithmus konnten also fünf klar unterscheidbare Kundensegmente identifiziert werden: Gelegenheitskäufer, Inaktive Kunden, Stammkunden,

Premiumkunden sowie Potenzialkunden. Diese Segmentierung wird in der finalen Visualisierung deutlich sichtbar (siehe Abbildung 4).

Diese Gruppen unterscheiden sich insbesondere in Kaufhäufigkeit, aktueller Aktivität sowie Umsatzvolumen erheblich. Dabei zeigte sich, dass ein Großteil der Kunden nur selten kauft und nur auch ebenfalls entsprechend adäquat geringe Umsätze erzeugt, während eine kleine Kundengruppe für einen großen Anteil des Umsatzes verantwortlich ist. Dies bestätigt den sogenannten Pareto-Effekt (80/20-Prinzip) und unterstreicht die Relevanz einer zielgerichteten Kundenansprache. Diese deckt sich mit Erkenntnissen aus bestehender Forschung im E-Commerce-Kontext (vgl. [L2]) und unterstreicht die Bedeutung datenbasierter Zielgruppenanalyse.

Die Clusterqualität wurde unter anderem über den verwendeten Silhouette-Score und Davies-Bouldin-Index bewertet und weist insgesamt auf eine stabile Segmentierung mit guter Trennschärfe hin. Besonders Cluster mit hoher Kaufaktivität und hohem Umsatz (Premiumkunden) heben sich klar von inaktiven oder einmaligen Käufern (logischerweise wie eigentlich erwartbar war) ab. Also ergeben sich für Unternehmen daraus praktische Handlungsmöglichkeiten, z.B. personalisierte Marketingkampagnen (genau abgestimmt auf die individuellen Kunden bzw. individuellen Kundengruppen), Bonusprogramme, Reaktivierungsstrategien und Upselling-Potenziale.

Fazit

Die Analyse zeigt demnach, dass eine Kundensegmentierung auf Basis historischer Transaktionsdaten ein sehr effektives Mittel ist, um unterschiedliche Käufergruppen zu identifizieren und gezielt anzusprechen. Durch die klare Abgrenzung der Cluster entsteht ein hoher Mehrwert für datenbasierte Geschäftsentscheidungen. Unternehmen können Marketing-Budgets effizienter einsetzen, Kundengruppen individuell adressieren und daraus dann sehr gut langfristig möglicherweise Wettbewerbsvorteile generieren (vgl. [L1]).

Insgesamt liefert das Modell demnach eine solide Grundlage, um Kundenverhalten besser zu versehen und datengetrieben zu steuern. Die finale Clusterstruktur (vgl. Abbildung 4) bestätigt die praktische Anwendbarkeit der Ergebnisse und steht im Einklang mit Literaturmodellen zur Kundensegmentierung (vgl. [L1], [L2]).

Ausblick

Trotz der überzeugenden Ergebnisse gibt es immer noch Potenzial für weiterführende Untersuchungen. Besonders interessant wäre eine zeitliche Betrachtung des Kaufverhaltens, um Dinge wie Trends, Saisonalität oder Kundenwanderungen abzubilden. Zudem könnte eine feinere Segmentierung innerhalb einzelner Cluster (beispielsweise durch zusätzliche Merkmale wie Produkttypen oder saisonale Muster) die Klassifikation noch weiter verbessern.

Wenn man nun beim gleichen Gedanken bleibt, wäre der Einsatz alternativer Modelle oder Vergleichsansätze (zum Beispiel DBSCNA, Hierarchisches Clustering oder neuronale Netze), um die Performance gegenüber K-Means zu evaluieren, auch denkbar bzw. möglich. Die Ergebnisse dieser Analyse dienen somit als eine Art stabile und robuste Basis für zukünftige Optimierungen und Erweiterungen im Bereich der kundenbasierten Datenanalyse.

Abschnitt 6: Quellen und Links

Anbei sind Informationen über verwendete Quellen und Links:

Informationen zu den Datensätzen:

	Name	Version / Datum	Kurzbeschreibung	Link
[D1]	Online Retail Dataset	Stand: 2011 (Originaldaten) / Abgerufen am 13.12.2025	Transaktionsdaten eines britischen Online-Retailers mit Rechnungen, Produkten, Mengen & Customer ID. Grundlage für RFM-Analyse & Clustering.	https://archive.ics.uci.edu/dataset/352/online+retail

Informationen zu den verwendeten Python Packages:

	Name	Version	Kurzbeschreibung	Link
[P1]	pandas	2.2.2	Datenverarbeitung & Manipulation von Tabellen-/CSV-Daten	https://pandas.pydata.org/docs/whatsnew/v2.2.2.html
[P2]	numpy	1.26.4	Numerische Berechnungen, Arrays & mathematische Operationen	https://pypi.org/project/numpy/1.26.4/
[P3]	scikit-learn	1.4.2	Machine-Learning-Bibliothek – Clustering, Modelle, Scaler	https://pypi.org/project/scikit-learn/1.4.2/
[P4]	matplotlib	3.8.4	Visualisierung – Erstellen von Plots/Diagrammen	https://pypi.org/project/matplotlib/3.8.4/
[P5]	StandardScaler / KMeans / silhouette_score / davies_bouldin_score (aus sklearn)	siehe P3	Genutzt zur Skalierung, Clusterbildung & Qualitätsmessung	Siehe P3 (Teile von scikit-learn)

Informationen zu verwendetem Beispielcode:

	Name	Version / Datum	Kurzbeschreibung der Verwendung	Link
[C1]	Eigenes Jupyter-Notebook zur Datenverarbeitung & Clusteranalyse	Erstellt am/zuletzt bearbeitet: Dezember 2025 – Januar 2026	Selbst geschriebener Code zur Datenbereinigung, Feature-Engineering (RFM-Berechnung), Skalierung, Clustering (K-Means) und Visualisierung	(lokal erstellt, kein externer Link)
[C2]	Beispiel-Code – Online Retail Dataset (UCI)	Abgerufen am: 10.12.2025	Initialer Code-Snippet von der UCI-Website zum Einlesen des Datensatzes mittels fetuch_ucirepo. In Projekt übernommen und angepasst (Weiterverarbeitung, Selektion)	https://archive.ics.uci.edu/dataset/352/online+retail

Informationen zu relevanter Fachliteratur:

	Autoren	Titel	Zeitschrift / Konferenz, Datum	Link falls frei verfügbar
[L1]	Chen, Daqing; Sain, S.; Guo, Q.	Data Mining for the Online Retail Industry: A Case Study of RFM Model-Based Customer Segmentation	Proceedings of the 5th International Conference on Machine Learning and Cybernetics, 2006	https://archive.ics.uci.edu/dataset/352/online+retail Paper verlinkt über Dataset-Seite: https://www.semanticscholar.org/paper/Data-mining-for-the-online-retail-industry%3A-A-case-Chen-Sain/e43a5a90fa33d419df42e485099f8f08badf2149
[L2]	Huang, Z.	Extension to the k-Means Algorithm for Clustering Large Data Sets with Categorical Values	1998	https://cdn.aaai.org/KDD/1998/KDD98-012.pdf

Abbildungen

Abbildung 1 – Datenausschnitt des Online Retail Datensatzes

IDs | Features | Date | Features

Beobachtungen
Samples

InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
536365	85123A	WHITE HANGING HEART T-LIGHT HOLDER	6	01.12.2010 08:26	2,55	17850	United Kingdom
536365	71053	WHITE METAL LANTERN	6	01.12.2010 08:26	3,39	17850	United Kingdom
536365	84406B	CREAM CUPID HEARTS COAT HANGER	8	01.12.2010 08:26	2,75	17850	United Kingdom
536365	84029G	KNITTED UNION FLAG HOT WATER BOTTLE	6	01.12.2010 08:26	3,39	17850	United Kingdom
536365	84029E	RED WOOLLY HOTTIE WHITE HEART.	6	01.12.2010 08:26	3,39	17850	United Kingdom
536365	22752	SET 7 BABUSHKA NESTING BOXES	2	01.12.2010 08:26	7,65	17850	United Kingdom
536365	21730	GLASS STAR FROSTED T-LIGHT HOLDER	6	01.12.2010 08:26	4,25	17850	United Kingdom
536366	22633	HAND WARMER UNION JACK	6	01.12.2010 08:28	1,85	17850	United Kingdom
536366	22632	HAND WARMER RED POLKA DOT	6	01.12.2010 08:28	1,85	17850	United Kingdom
536367	84879	ASSORTED COLOUR BIRD ORNAMENT	32	01.12.2010 08:34	1,69	13047	United Kingdom
536367	22745	POPPY'S PLAYHOUSE BEDROOM	6	01.12.2010 08:34	2,1	13047	United Kingdom
536367	22748	POPPY'S PLAYHOUSE KITCHEN	6	01.12.2010 08:34	2,1	13047	United Kingdom
536367	22749	FELTCRAFT PRINCESS CHARLOTTE DOLL	8	01.12.2010 08:34	3,75	13047	United Kingdom
536367	22310	IVORY KNITTED MUG COSY	6	01.12.2010 08:34	1,65	13047	United Kingdom
536367	84969	BOX OF 6 ASSORTED COLOUR TEASPOONS	6	01.12.2010 08:34	4,25	13047	United Kingdom
536367	22623	BOX OF VINTAGE JIGSAW BLOCKS	3	01.12.2010 08:34	4,95	13047	United Kingdom
536367	22622	BOX OF VINTAGE ALPHABET BLOCKS	2	01.12.2010 08:34	9,95	13047	United Kingdom
536367	21754	HOME BUILDING BLOCK WORD	3	01.12.2010 08:34	5,95	13047	United Kingdom
536367	21755	LOVE BUILDING BLOCK WORD	3	01.12.2010 08:34	5,95	13047	United Kingdom
536367	21777	RECIPE BOX WITH METAL HEART	4	01.12.2010 08:34	7,95	13047	United Kingdom

Beschreibung:

Diese Abbildung zeigt einen Ausschnitt des ursprünglichen „Online-Retail"-Datensatzes, aus dem unsere Analyse hervorgegangen ist. Sichtbar sind einzelne Transaktionen mit Produktinformationen (StockCode, Description), Kaufmengen (Quantity), Preisen (UnitPrice), dem Kaufdatum (InvoiceDate) und einer CustomerID, über die Käufe einem einzelnen Kunden zugeordnet werden können. Jede Zeile stellt einen Einkaufsvorgang dar und bildet damit die Basis der späteren Aggregation auf Kundenebene.

Die Ansicht ist wichtig, um die Struktur des Datensatzes zu verstehen und nachzuvollziehen, welche Schritte anschließend zur Datenaufbereitung notwendig waren. Insbesondere wird ersichtlich, dass recency-basiertes Verhalten erst über das Kaufdatum berechnet werden kann und der monetäre Wert eines Einkaufs nicht direkt vorliegt, sondern über die Quantity * PriceUnit erzeugt werden muss. Ebenso wird deutlich, dass Kunden mehrfach auftreten und daher eine Verdichtung zu Recency-, Frequency- und Monetary-Werten nötig ist.

Die Abbildung bildet also die Grundlage der gesamten Analyse, da sie zeigt, wie Rohdaten in ein RFM-Modell transformierbar sind und welche Informationen das spätere Clustering tragen.

Abbildung 2 – Scatterplot Recency vs Monetary

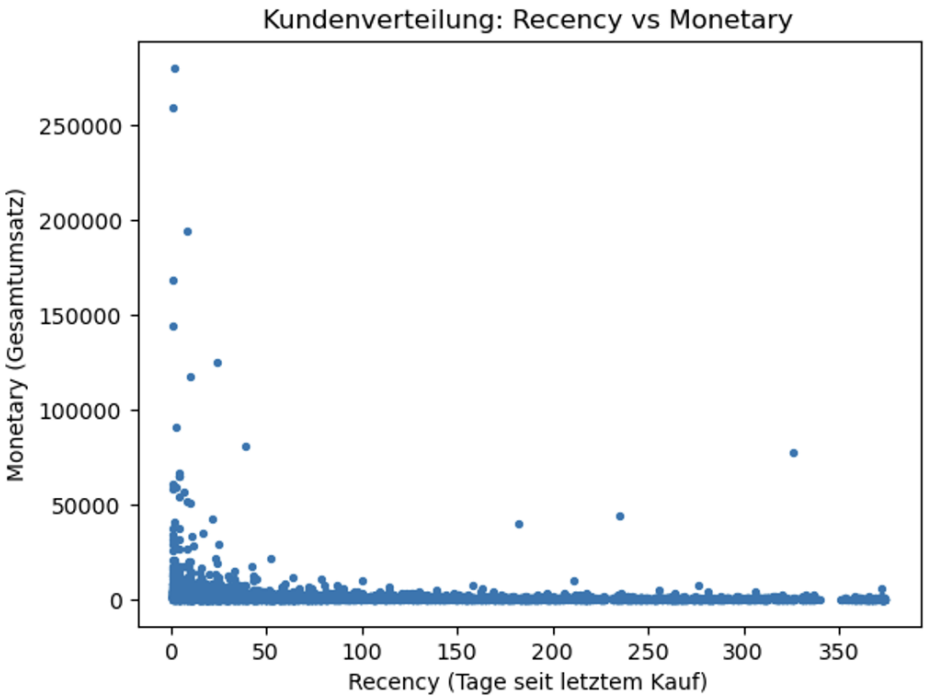

Beschreibung:

Diese Abbildung zeigt den Scatterplot der Merkmal Recency (Tage seit letztem Kauf) und Monetary (Gesamtumsatz pro Kunde). Jeder Punkt repräsentiert einen Kunden. Auf der x-Achse ist zu sehen, wie lange der letzte Kauf zurückliegt, während die y-Achse den erzeugten Umsatz darstellt. Auffällig ist, dass ein Großteil der Kunden nur geringe Umsätze generiert und dabei häufig lange nicht mehr aktiv war. Gleichzeitig existieren wenige Kunden, die sehr hohe Umsätze aufweisen, was auf wertvolle Premiumkunden hindeutet.

Die Verteilung zeigt eine deutliche Rechtsschiefe, wodurch ersichtlich wird, dass hohe Umsätze von wenigen Individuen entstehen (das ist ein typischer Hinweis auf den Pareto-Effekt). Daraus kann nun abgeleitet werden, dass Kundengruppen sehr unterschiedlich handeln und eine Segmentierung sinnvoll ist. Die Abbildung bestätigt also vor dem Clustering, dass es verschiedene Verhaltensmuster gibt, beispielweise „viel Umsatz aber selten“, „wenig Umsatz aber aktiv“ oder „lange inaktiv und geringes Volumen“. Demnach ist die Visualisierung der erste solide Hinweis bzw. Nachweis, dass Clusterbildung einen Mehrwert liefern wird.

Abbildung 3 – Silhouette-Score zur Bestimmung von k

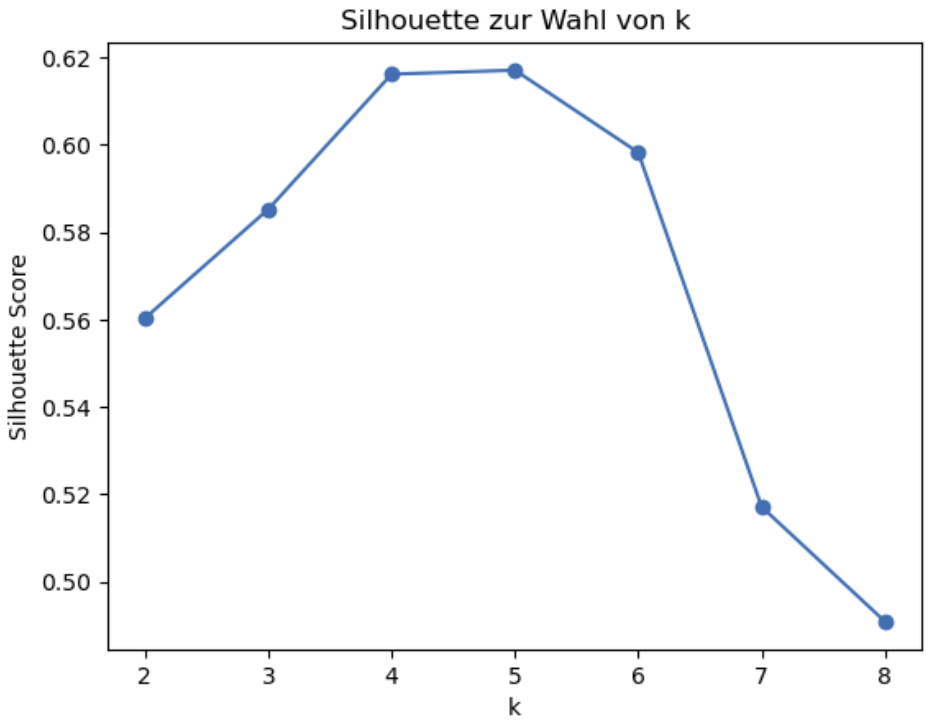

Beschreibung:

Die dritte Abbildung zeigt den Silhouette-Score für unterschiedliche Clusterzahlen (k von 2 bis 8). Dieser Score bewertet, wie gut sich Cluster voneinander abgrenzen lassen und wie kompakt die Gruppen intern sind. Höhere Werte stehen für klar trennbare Cluster und niedrige Werte signalisieren Überlappungen. Der höchste Wert wird bei k = 5 erreicht, dann folgt k = 4. Ab k > 5 fällt der Score sehr deutlich ab, was wiederum bedeutet, dass zusätzliche Cluster keine besseren Strukturen erzeugen, sondern eher zu Überschneidungen führen.

Aus diesem Diagramm lässt sich daher untermauert ableiten, dass 5 Cluster die optimale Wahl in dieser Situation darstellen. Die Clusterstruktur ist also bei k = 5 am stabilsten, am saubersten getrennt und auch ausreichend feingranular, um differenzierte Kundensegmente zu identifizieren. Die Entscheidung für k = 5 basiert daher nicht subjektiv, sondern objektiv (angelehnt an ein Qualitätskriterium). Die Visualisierung ist daher ein zentraler Schritt (im Sinn einer Validierung), bevor die finale Segmentierung durchgeführt wird.

Abbildung 4 – Finale Kundensegmente (Ergebnis der K-Means-Analyse)

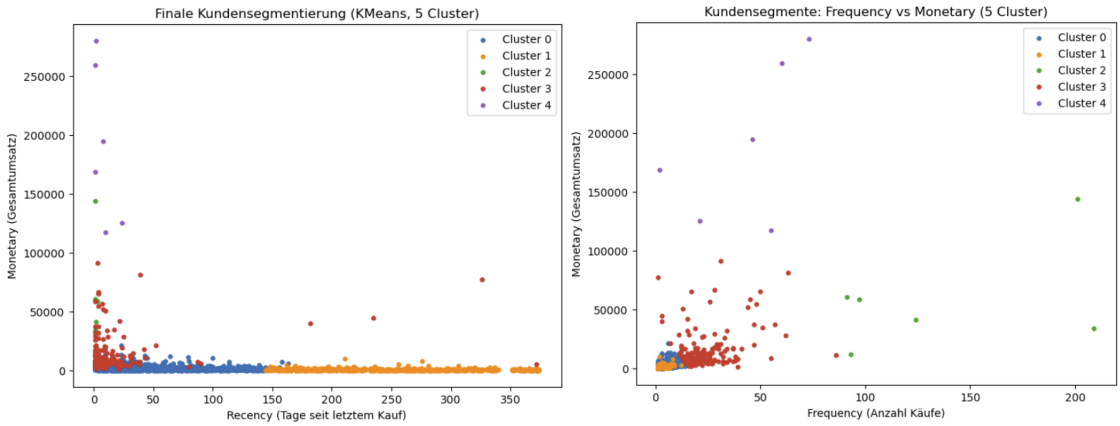

Beschreibung:

Diese zweiteilige Abbildung zeigt das finale Ergebnis der Kundensegmentierung mit k = 5 Clustern. Jeder Punkt stellt einen Kunden dar, und zwar farblich einem Segment zugeordnet. Die Darstellung erfolgt hier zum einen als Plot Recency vs Monetary und zum anderen als Plot Frequency vs Monetary, wodurch Clusterverteilung aus zwei Perspektiven sichtbar wird. Die Cluster sind gut voneinander getrennt und zeigen eindeutige Verhaltensmuster.

Aus den Gruppen lassen sich folgende Profile ableiten:

Cluster 0 repräsentiert Gelegenheitskäufer mit niedrigen Umsätzen und längeren Kaufabständen.

Cluster 1 umfasst weitgehend inaktive Kunden, die seit langer Zeit nicht mehr gekauft haben.

Cluster 2 zeigt regulär kaufende Stammkunden mit durchschnittlichen Volumen.

Cluster 3 enthält Premium- bzw. Vielkäufer (wertvollste Kundengruppe, hoher Frequenz & Umsatz).

Cluster 4 bildet Potenzialkunden ab, die zuletzt aktiv waren und steigende Käufe aufweisen (Upselling).

Diese Abbildung wiederum ist der Kern der gesamten Arbeit, da sie die Nutzbarkeit des Clustering-Ansatzes bestätigt und direkt in Marketingstrategien übersetzbar macht. Sie zeigt sehr gut, wie unterschiedliche Kundensegmente datengetrieben identifiziert werden können und bildet die Basis für Handlungsempfehlungen, zum Beispiel: gezielte Rabatte für Cluster 0 & 1 oder exklusive Programme für Cluster 3.